

BIOINFORMATICS & INTELLIGENT ENGINEERING

바이오 데이터 이해 및 LLM 기반 전처리 실전 가이드

비정형 생명과학 데이터의 한계 극복부터 거대언어모델(LLM)을 활용한 시맨틱 표준화와
파이프라인 구축

— 차세대 바이오 데이터 사이언스 시리즈

현황 분석

바이오 데이터 폭발과 구조적 한계

80%+

비정형 데이터 비중

의무기록 서술문, 실험 프로토콜 노트

40EB

2025년 누적 유전체 규모

연간 35% 이상 지수함수적 증대

70%

전처리 투입 공수

전체 바이오 AI 연구 기간 기준

4대 핵심 바이오 데이터 모달리티



유전체 서열

DNA 및 RNA 염기서열.
FASTA, FASTQ, VCF 표준



단백질 입체구조

원자 좌표계 및 결합 정보.
PDB, mmCIF, AlphaFold DB



임상 의무기록

비정형 진료 소견 및 처방.
EMR, EHR, 임상시험 보고서



학술 문헌

약물 기전과 상호작용 지식.
PubMed, PMC, 바이오아카이브

전통적 전처리 방식의 근본적 난제

⚠ 규칙 기반(Regex) 파서의 한계

동의어 폭증: 단일 단백질당 평균 5개 이상 명칭.

문맥 단절: 부정문과 조건부 가설 식별 실패.

유지보수 비용: 서식 변경 시마다 규칙 재작성.

👥 수작업 큐레이션의 병목

극심한 비용: 석·박사급 전문 큐레이터 필수.

작업 편차: 큐레이터 간 라벨링 일치율 75% 미만.

처리 지연: 신규 논문 분석 지연 누적.

LLM 기반 시맨틱 전처리로의 전환

문맥 기반 개체명 인식 (Bio-NER)

복잡한 문맥 속에서도 유전자와 약물 표적 자동 식별.

동적 온톨로지 정합성 매핑

비표준 용어를 MeSH 및 SNOMED CT 코드로 자동 연계.

JSON 구조화 및 스키마 강제

자유 서술문을 다운스트림 모델용 표준 포맷으로 즉시 변환.



LLM 기반 바이오 데이터 전처리 4단계

01

문맥 청킹

원문 문서 분할.
생물학적 단락 단위 보존

02

개체 추출

바이오 엔티티 식별.
유전자, 변이체, 질병 매핑

03

온톨로지 정합


표준 코드 변환.
UMLS, MeSH ID 정합

04

스키마 검증

JSON 무결성 검사.
Pydantic 규칙 필터링

비정형 의무기록(EMR) 정제 및 표준화



병원별 약어 및 불규칙 서식 해소

다양한 임상 축약어를 표준 의학 용어로 자동 교정.

환자 시계열 투약 이력 구조화

자유 서술형 투약 메모를 시간대별 복용 테이블로 변환.

개인식별정보(PII) 자동 비식별화

환자 성명 및 고유번호 마스킹을 전처리 단계에서 동시 수행.

바이오 시퀀스 메타데이터 표준화



FASTA 헤더 파싱

불규칙 서열 설명 분해.

단백질 ID 및 유전자 기호 자동 분류



생물종 온톨로지 매핑

NCBI Taxonomy ID 연계.

이명 및 일반 명칭의 학명 단일화



실험 메타데이터 검증

MIAME 표준 준수 자동 점검.

시퀀싱 플랫폼 누락값 자동 경고

환각 방지 및 바이오 무결성 보장

온톨로지 제약 디코딩

사전 정의 ID만 출력 강제.
가상 유전자 생성 위험 100% 원천 차단

RAG 기반 근거 교차 검증

공식 DB 실시간 검색 대조.
UniProt 및 PubChem API 실시간 대조

전문가 휴먼인더루프(HITL)

임계값 미달 데이터 선별 검수.
신뢰도 90% 이하 항목만 큐레이터 배정

전처리 효율성 및 정밀도 정량 비교

규칙 기반 파이프라인 (기존)

58.4%

LLM + 온톨로지 제약 파이프라인 (제안 모델)

94.8%

-82%

문헌 정제 소요 시간

10x

일일 데이터 처리량 증대

99.1%

스키마 정합 유효성 통과율

향후 로드맵: 바이오 파운데이션 모델 연계



도메인 특화 SLM 도입

온프레미스 경량 모델 운용.
민감 의료 데이터 내부 처리 보장



멀티모달 통합 파운데이션

서열과 문헌의 동시 임베딩.
텍스트와 아미노산 서열 통합 분석



자율형 큐레이션 에이전트

자가 수정 루프 탑재.
이상치 발견 시 능동적 재검증 수행