

BIOINFORMATICS DATA SCIENCE & PRACTICAL ANALYTICS

바이오 데이터 EDA · 통계 · 시각화 자동화

분포·상관관계 자동 생성부터 실험군/대조군 비교 및 Sephora 화장품 데이터 실습까지

—— 데이터 기반 바이오·코스메슈티컬 전문 강의 교재

강의 핵심 3대 학습 모듈



EDA 자동 생성

분포 및 상관관계 자동화.

왜도, 첨도, 다변량 결측치 프로파일링



가설 검정 & 통계

실험군과 대조군 비교.

t-검정, 분산분석 및 Volcano 플롯



Sephora 데이터 실습

가격·평점·성분 분석.

코스메틱 바이오 마커 및 다변량 회귀 실습

바이오 데이터 분포 탐색 및 자동 프로파일링

비대칭 편향 극복과 정규성 점검

극단적 우측 꼬리 분포 확인 시 Log 변환 자동 적용.

다차원 결측치 패턴 진단

기계적 미검출(LOD)과 무작위 결측의 자동 판별.

이상치(Outlier) 신속 감지

IQR 및 Z-score 기반 칩 노이즈 이상치 사전 선별.

주요 자동화 통계량 지표

왜도 (Skewness)

비대칭도 판정

첨도 (Kurtosis)

중심 밀집도 측정

피어슨 / 스피어만

선형·순위 상관

결측치 비율

자동 보간 가이드

상관관계 및 고차원 구조 시각화 유형



상관 행렬 히트맵

변수 간 상호작용 파악.

군집 계층 클러스터링 동시 표기



바이올린 플롯

다중 그룹의 확률 밀도 비교.

사분위수 및 발현량 분포 직관화



PCA 차원 축소 산점도

샘플 군집화 경향 확인.

배치 효과 및 주요 분산 요인 식별

실험군 · 대조군 비교 및 유의성 검정

모수 vs 비모수 통계 검정 자동화


정규성 검정 결과에 따라 Student t-test 또는 Mann-Whitney 자동 채택.

변화 배수 (Fold Change) 산출

실험군과 대조군 사이의 발현 강도 비율 계산 ($\text{Log}_2\text{FC} > 1.5$ 기준 적용).

Volcano Plot 핵심 요약

통계적 유의성($-\log_{10} p\text{-value}$)과 발현 차이의 동시 시각화.



다중 가설 검정과 거짓 발견율 (FDR) 보정

⚠ 다중 검정 시 제1종 오류 폭증

위양성 위험: 3만 개 프로브 검정 시 수천 개 가짜 유의성 발생.

본페로니 한계: 과도하게 보수적이어서 진짜 표적 누락.

연구 재현성 저하: 보정 미실시 데이터는 후속 검증 실패.

🛡 Benjamini-Hochberg (BH) 자동 보정

FDR 통제: 거짓 발견 비율을 5% 이하($q < 0.05$)로 엄격 제한.

검정력 보존: 생체 지표의 신뢰도와 탐색 효율을 동시 확보.

자동 임계치 필터링: 파이프라인 내 유의 유전자 자동 랭킹.

Sephora 화장품 데이터셋 구조 및 특징



실제 이커머스 바이오·코스메틱 데이터

스킨케어 제품 수천 건의 가격, 리뷰 평점 및 전성분 텍스트.

가격과 소비자 평점의 관계 분석

고가 프리미엄 제형이 실제로 더 높은 만족도를 유발하는지 통계 검증.

유효 기능성 성분 토큰화

히알루론산, 레티놀, 나이아신아마이드 등 주요 원료의 평점 기여도 산출.

가격 · 평점 · 성분 3차원 관계 규명



가격대별 세그먼트 분석

일원배치 분산분석(ANOVA).

저가/중가/고가 군 간 평점 유의차 확인



성분 기반 원-핫 인코딩

희소 바이오 매트릭스 변환.

수백 개 화학 성분의 포함 여부 수치화



다중 선형 & 릿지 회귀

평점 유발 핵심 성분 도출.

성분별 회귀 계수(Beta) 및 기여도 시각화

자동화 실습 파이프라인 4단계

01

데이터 정제

이상치 및 결측 처리.
특수기호 전성분 정규화

02

EDA 자동 생성

분포 및 산점도 출력.
가격 대수변환(Log) 적용

03

가설 검증 수행

집단 간 유의성 검정.
ANOVA 및 Tukey 사후분석

04

인사이트 도출

핵심 기여 성분 랭킹.
결과 리포트 자동 컴파일

EDA 및 가설 검증 자동화 효율성 비교

전통적 수작업 코드 작성 및 그래프 생성 소요 시간 (평균)

4.5 시간

자동화 파이프라인 적용 시 소요 시간 (프로파일링 + 플롯)

0.4 시간 (-91%)

10x+

분석 및 리포팅 생산성 향상

100%

다중 검정 FDR 보정 준수율

0.87

성분-평점 다변량 모델 설명력(R^2)