

GENOMICS AI & CLINICAL INFORMATICS

바이오 예측 모델 및 분석 리포트 자동화

유전자 발현 기반 분류·회귀 모델링부터 LLM 결합 임상 분석 리포트 자동 생성까지

데이터 기반 정밀의료 머신러닝 실무 강의 교재

바이오 예측 자동화 3대 핵심 학습 모듈



유전자 특성 추출

고차원 희소 데이터 압축.

LASSO 및 분산 기반 중요 프로브 선별



분류 & 회귀 모델링

질환 및 약물 반응 예측.

XGBoost, ElasticNet 및 교차 검증



리포트 자동 생성

LLM 연계 임상 리포트 발행.

SHAP 기전 해석 및 표준 양식 컴파일

고차원 유전자 발현 특성 선택 및 차원 축소

차원의 저주($p \gg n$) 극복 전략

수만 개 유전자 중 질환 신호와 직결된 핵심 바이오마커만 압축 선별.

임베디드 L1 정규화 (LASSO)

불필요한 노이즈 유전자의 회귀 계수를 0으로 수렴시켜 희소 모델 완성.

상관 기반 다중공선성 제거

동일 생체 경로 상의 중복 유전자를 클러스터링하여 과적합 원천 방지.

특성 선별 알고리즘 프로파일

분산 임계치 필터

무변화 유전자 배제

상호 정보량(Mutual Info)

비선형 연관성 포착

RF 중요도(MDI)

트리 분기 기여도

최종 선별 피쳐 수

상위 50~200개 유전자

유전자 발현 기반 질환 진단 및 아형 분류



서포트 벡터 머신 (SVM)

고차원 공간 결정 경계 도출.
선형 커널을 통한 안정적 이진 분별



XGBoost & LightGBM

부스팅 앙상블 비선형 학습.
복합 유전자 상호작용 반영 극대화



정규화 로지스틱 회귀

확률 기반 임상 점수화.
진단 오즈비(Odds Ratio) 직접 산출

약물 반응성(IC50) 및 연속형 지표 예측

연속형 약물 감수성 수치 예측


환자 유전자 프로파일로부터 항암제 반응 농도(IC50) 회귀 추정.

엘라스틱넷(ElasticNet) 회귀

L1과 L2 패널티를 동시 적용하여 연관 유전자 군집을 함께 보존.

평가 지표 자동 집계

RMSE, MAE 및 피어슨 결정계수(R^2)를 기반으로 예측 신뢰도 측정.



데이터 누수 방지와 교차 검증 파이프라인

⚠ 바이오 ML의 데이터 누수 함정

사전 정규화 오류: 전체 데이터 일괄 스케일링 시 정보 누출.

분할 전 피처 선택: 테스트셋 타겟 정보가 선별에 반영.

과장된 성능 지표: 실제 독립 외부 검증 시 정확도 급락.

🛡 파이프라인 기반 자동 격리 검증

폴드 내 변환 격리: 훈련용 폴드 내부에서만 정규화 적합.

Stratified K-Fold: 희귀 질환 클래스 비율 완벽 보존.

독립 코호트 검증: 병원 간 배치 효과 극복 일반화 확인.

설명 가능한 AI (XAI)

SHAP 기전 해석 및 생물학적 타당성 규명



SHAP 기여도 분해

샤플리 값 산출.

환자별 유전자 기여도 양/음 영향 정량화



경로(Pathway) 농축 연계

KEGG 및 GO 매핑.

선별 유전자 생물학적 신호전달체계 연결



의료진 신뢰성 확보

블랙박스 인공지능 해소.

근거 중심 임상 의사결정 보조 자료 제공

분석 수치와 LLM 결합 리포트 생성 엔진



정량 수치 JSON 자동 추출 및 주입

ROC-AUC, 주요 톱 유전자 목록을 템플릿 슬롯에 직접 매핑.

문맥 기반 임상 해설 자동 생성

LLM이 해당 유전자 변이의 최신 논문 문헌과 연계해 요약문 작성.

규격화된 PDF/HTML 원클릭 빌드

병원 및 연구소 표준 템플릿에 맞춘 종합 리포트 즉시 발행.

데이터 인입부터 리포트 발행까지 4단계

01

발현 데이터 전처리

정규화 및 배치 보정.
Clean Matrix 자동 생성

02

AutoML 예측 학습

하이퍼파라미터 탐색.
최적 분류·회귀 모델 확정

03

기전 해석 추출

SHAP 기여도 연산.
유의 경로 자동 농축

04

리포트 문서 발행

LLM 요약문 결합.
연구자/의료진 전달 완성

예측 모델링 및 리포트 작성 자동화 생산성 비교



15x+

분석 및 리포트 작성 속도 향상

0.94

질환 판별 평균 ROC-AUC 지표

100%

실험 재현성 및 표준 리포트 규격화

머신러닝



01 지도학습과 비지도학습



지도학습

(Supervised Learning)



고양이!

장점 손쉽게 모델의 성능을 평가할 수 있음

단점 레이블이 없는 데이터는 레이블을 달기 위해 많은 시간을 투자해야 하는 단점 존재

대표적 예 분류, 회귀

01 지도학습과 비지도학습



비지도학습

(Unsupervised Learning)



데이터의 특성을
스스로 파악



장점 별도로 레이블을 제공할 필요가 없으므로
시간 절약 가능

단점 레이블이 없으므로 모델의 성능을
평가하는 데 다소 어려움이 있음

대표적 예 클러스터링, 차원 축소

02 분류와 회귀



데이터가 입력되었을 때 지도 학습을 통해
미리 학습된 레이블 중 하나 또는 여러 개의 레이블로
예측하는 것

이진 분류

둘 중
하나의 값으로 분류



남 / 여 중 분류

다중 분류

여러 개 중
하나로 분류

0 1 2 3 4
5 6 7 8 9

0~9 중 하나

다중 레이블 분류

두 개 이상의
레이블로 분류




뉴스 카테고리 분류


02 분류와 회귀

분류와 회귀의 비교

분류



회귀



03 과대적합과 과소적합

과대적합(overfitting)

- 학습 데이터에 대한 정확도는 매우 높지만 테스트 데이터 또는 학습 데이터 외의 데이터에는 정확도가 낮게 나오는 것(분산이 높음)



04 혼동 행렬

		예측 클래스 (Predicted Class)	
		Negative(0)	Positive(1)
실제 클래스 (Actual Class)	Negative(0)	TN (True Negative)	FP (False Positive)
	Positive(1)	FN (False Negative)	TP (True Positive)

04 혼동 행렬

TP(True Positive)

- 맞는 것을 올바르게 예측한 것
- 암환자를 암환자로 예측

		예측 결과	
		암환자	일반인
실제 정답	암환자	5	2
	일반인	1	2




04 혼동 행렬

FP(False Positive)

- 틀린 것을 맞다고 잘못 예측한 것
- 일반인인데 암환자로 잘못 예측

		예측 결과	
		암환자	일반인
실제 정답	암환자	5	2
	일반인	1	2



05 머신러닝 모델의 성능 평가

정확도 (Accuracy)

- 입력된 데이터에 대해 올바르게 예측한 비율
- 혼동 행렬 상에서는 대각선을 전체 셀로 나눈 값에 해당



정확도 =
$$\frac{TP + TN}{(TP + FN + FP + TN)}$$

05 머신러닝 모델의 성능 평가

정밀도(Precision)

- 모델의 예측 값이 얼마나 정확하게 예측됐는가를 나타내는 지표
- False를 True라고 판단하면 안되는 경우 중요



$$\text{정밀도} = \frac{TP}{(TP + FP)}$$

05 머신러닝 모델의 성능 평가

재현율(Recall)

- 실제 값 중에서 모델이 검출한 실제 값의 비율을 나타내는 지표
- True를 False로 잘못 판단하면 큰일나는 경우 중요
- 정밀도와 재현율은 trade-off 관계



재현율

$$\text{재현율} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

05 머신러닝 모델의 성능 평가

■ F1 score

- 정밀도와 재현율 두 값을 조합하여 하나의 수치로 나타낸 지표
- 데이터의 레이블이 불균일하게 분포돼 있을 경우, 정확도는 왜곡된 성능 평가로 이어질 수 있으므로 사용

$$\text{F1 score} = \frac{2 * \text{precision} * \text{recall}}{\text{precision} + \text{recall}}$$

05 머신러닝 모델의 성능 평가

■ K-폴드 교차 검증(K-fold cross validation)


- 학습 데이터의 일정 부분을 검증데이터로 쓰되, n번의 검증 과정을 통해 학습 데이터의 모든 데이터를 한 번씩 검증데이터로 사용하는 방식
- Training Set, Validation Set, Test Set의 개념 구분

장점


- 검증 결과가 일정 데이터에 치우치지 않고 모든 데이터에 대한 결과이므로 신빙성이 높음
- 별도로 검증 데이터를 분리하지 않아도 됨

05 머신러닝 모델의 성능 평가

■ K-폴드 교차 검증(K-fold cross validation)



K-폴드 교차 검증



앙상블(Ensemble)

: 결정트리 기반 알고리즘을 결합하여 구현

[앙상블 종류 요약]

- (1) Voting : 서로 다른 알고리즘 가진 분류기를 결합, 사이킷런은 VotingClassifier 클래스를 제공함

<1> 하드보팅(Hard Voting) : 분류기들이 예측한 결과 값을 다수결로 결정

<2> 소프트 보팅(Soft Voting) : 각 분류기들이 예측 값을 확률로 구하면 이를 평균 내어 확률이 가장 높은 값을 결과 값으로 결정

(2) Bagging : 같은 유형의 알고리즘을 결합, 데이터 샘플링시 서로 다르게 가져가면서 학습, RandomForest 가 대표적, Bootstrapping Aggregation 줄임말

(Bootstrapping : 여러개의 데이터 세트를 중첩되게 분리하는 분할 방식

(3) Boosting : 여러개의 분류기가 순차적으로 학습하면서 가중치를 부스팅한다, XGBoost(캐글 대회 상위 석권),LightGBM


AdaBoost 알고리즘 참고사이트: <https://dohk.tistory.com/217>

Bagging

랜덤포레스트(RandomForest)

- 의사 결정 트리 기반(Decision Tree) 기반 분류 알고리즘
- 앙상블(Ensemble), 같은 결정트리를 여러개 사용, 비교적 빠른 수행
- 현재의 랜덤 포레스트의 개념은 레오 브레이먼(Leo Breimen)의 논문에서 만들어짐, 이 논문은 랜덤 노드 최적화(Randomized Node Optimization, RNO)와 배깅(bagging)을 결합한 방법과 같은 CART(Classification And Regression Tree)를 사용해 상관관계가 없는 트리들로 포레스트를 구성하는 방법을 제시했다

PCA(Principal Component Analysis)의 이해



K-Means Clustering

군집 중심점(Centroid) 기반 클러스터링

