

NCBI GEO & LLM AUTOMATION PIPELINE

# NCBI GEO 유전자 발현 데이터와 LLM 기반 전처리 파이프라인

실제 마이크로어레이(GSM827073) 데이터 분석 사례 및 지능형 자동화 전처리 전략

—— 바이오인포매틱스 데이터 사이언스 시리즈

# 글로벌 최대 유전자 발현 저장소 GEO

## 전 세계 생명과학 데이터 공공 아카이브


수백만 건의 마이크로어레이 및 RNA-Seq 발현체 데이터 보유.

## 실험 메타데이터와 수치 행렬 결합

실험 프로토콜 텍스트와 개별 프로브 신호 수치가 단일 파일에 공존.

## 신약 발굴과 질환 바이오마커 연구의 핵심

환자군과 대조군 사이의 차등 발현 유전자(DEG) 분석 기반.



## 유전자 발현 바이오 데이터의 3대 핵심 특성



### 초고차원성 특성

수만 개 프로브 동시 기록.

단일 샘플당 45,000개 이상 발현치 집계



### 장비별 비표준 포맷

스캐너 벤더별 서식 상이.

Agilent 및 Illumina 간 헤더 규칙 불일치



### 노이즈 및 배경 신호

실험 오차 보정 필수.

백그라운드 차감 및 Log2 정규화 선행 요구

# Agilent 스캐너 텍스트 파일 내부 구조

## FEPARAMS

### 실험 메타데이터 구역

스캐너 사양과 격자 정보.

G2505C 장비 식별자 및 스캔 날짜 기록

## STATS

### 신호 품질 통계 구역

품질 관리(QC) 수치 지표.

스캔 강도 분포 및 컨트롤 스팟 통계 제공

## FEATURES

### 핵심 발현치 데이터 구역

프로브별 실제 수치 행렬.

ProbeName, gProcessedSignal 포함

## 전통적 수동 파싱 및 전처리의 근본적 한계

### 비정형 혼재 포맷의 파싱 결함

**표 형식 로더 불가:** 다중 헤더 구역 혼재로 오류 발생.

**정규표현식 취약성:** 스캐너 펌웨어 변경 시 코드 파손.

**메타데이터 유실:** 발현치만 추출되고 조건 정보 분실.

### 대규모 수작업 큐레이션의 지연

**연구 공수 낭비:** 전체 연구 기간의 70%가 전처리에 집중.

**컨트롤 필터링 혼선:** 연구자별 상이한 스파이크 필터 기준.

**배치 확장 불가:** 수백 개 샘플 대상 일괄 자동화 실패.

# LLM 기반 바이오 데이터 전처리의 패러다임 전환



## 문맥 인지 분할

메타데이터 자율 식별.

비정형 헤더 구역과 매트릭스 구역 자동 분리



## 자연어 파이프라인 생성

도메인 코드 즉각 합성.

원하는 정제 규칙을 Python/R 코드로 자동 구현



## 온톨로지 정합성 매핑

표준 스키마 규격화.

NCBI Gene ID 및 통일 JSON으로 정규화

# GSM827073 파일 자동 전처리 4단계

01

## 구조 파악

헤더 및 데이터 분리.  
FEATURES 키워드 감지

02

## 컬럼 인식

필수 변수 자동 매핑.  
ProbeName, Signal 식별

03

## 컨트롤 필터

유효 유전자 선별.  
ControlType = 0 조건 반영

04

## 정규화 완료

Log2 발현 행렬 변환.  
분석용 Clean Matrix 산출

도입 성과

## 전처리 자동화 도입 전후 정량 비교

전통적 수동 정규식 파서 처리 성공률

52.6%

LLM 기반 시맨틱 자동화 파이프라인

96.4%

**-85%**

전처리 스크립트 작성 시간

**12x**

대량 배치 일괄 처리 속도

**99.8%**

타겟 프로브 필터링 정확도