

Sephora 화장품 데이터셋 설명 및 탐색적 데이터 분석(EDA)

보고서

본 문서는 글로벌 뷰티 스토어 **Sephora(세포라)**의 제품 데이터를 활용하여 화장품의 가격, 평점, 리뷰 수, 성분 간의 관계를 분석하고, 실무적인 비즈니스 인사이트를 도출하기 위한 분석 설계 문서입니다.

1. 데이터셋 개요 (Dataset Overview)

Sephora 데이터셋은 스킨케어, 메이크업, 헤어케어 등 다양한 카테고리의 뷰티 제품 정보를 담고 있습니다. 이 데이터는 소비자 행동 분석, 제품 가격 정책 수립, 성분 트렌드 파악 등에 널리 활용됩니다.

1.1. 주요 변수 (Features) 설명

변수명 (Column)	데이터 타입	설명 (Description)
brand	문자열 (String)	제품의 브랜드명 (예: Estée Lauder, The Ordinary, Drunk Elephant)
category	문자열 (String)	제품군 분류 (예: Moisturizers, Serums, Cleansers)
price	실수형 (Float)	제품 가격 (USD 기준)
rating	실수형 (Float)	사용자 평균 평점 (0.0 ~ 5.0)
number_of_reviews	정수형 (Integer)	해당 제품에 작성된 총 리뷰

변수명 (Column)	데이터 타입	설명 (Description)
		수
ingredients	문자열 (String)	제품에 포함된 전성분 텍스트 리스트
clean_at_sephora	논리형 (Boolean)	유해 의심 성분이 배제된 '클린 뷰티' 인증 마크 여부 (True/False)

2. 탐색적 데이터 분석 (EDA) 방향성

본격적인 통계 검정에 앞서, 데이터의 전반적인 형태를 파악하는 탐색적 분석을 수행합니다.

- 가격(Price) 분포 분석:
 - 화장품 가격은 일반적으로 오른쪽으로 꼬리가 긴(Right-skewed) 분포를 보입니다.
 - 로그 변환(Log-transformation)을 적용하여 정규성을 확보한 후 분석을 진행하는 것이 효과적입니다.
- 평점(Rating) 및 리뷰(Reviews) 분포 분석:
 - Sephora 제품의 평점은 대부분 4.0 이상에 밀집되어 있는 '평점 인플레이션' 경향이 있습니다.
 - 리뷰 수는 소수의 베스트셀러가 압도적으로 많은 불균형(Pareto) 분포를 보입니다.

3. 주요 변수 간 상관관계 및 통계 분석

3.1. 가격과 평점의 상관관계 (Price vs Rating)

고가의 화장품일수록 소비자의 평점이 높을까요? 이를 확인하기 위해 피어슨 상관계수(Pearson Correlation) 또는 스피어만 순위 상관계수(Spearman Rank Correlation)를 계산합니다.

- 가설: 제품 가격과 사용자 평점 사이에는 양의 상관관계가 있을 것이다.
- 분석 방법: 산점도(Scatter Plot) 시각화 및 상관계수 산출. 보통 뷰티 제품의 경우 가격과 평점의 직접적인 상관관계는 약하게 나타나는 경향이 있습니다(가성비 제품의 높은 평점 존재).

3.2. 카테고리별 가격 분산 분석 (ANOVA)

스킨케어, 메이크업, 향수 등 제품군 간에 유의미한 가격 차이가 있는지 확인합니다.

- 분석 방법: 일원배치 분산분석(One-way ANOVA) 적용. 사후 분석(Tukey HSD)을 통해 구체적으로 어떤 카테고리 간에 가격 차이가 큰지 규명합니다.

4. 성분(Ingredients) 기반 심층 분석

제품의 성분 텍스트 데이터를 파싱(Parsing)하여, 특정 트렌드 성분이 제품의 가격 및 평점에 미치는 영향을 분석합니다. (실험군 vs 대조군 비교)

4.1. 주요 활성 성분(Active Ingredients) 유무에 따른 차이 분석

예를 들어, 'Hyaluronic Acid(히알루론산)', 'Retinol(레티놀)', 'Peptide(펩타이드)'와 같은 고기능성 성분이 포함된 제품과 그렇지 않은 제품을 나눕니다.

- 실험군: 특정 고기능성 성분 포함 제품
- 대조군: 미포함 제품
- 통계 검정: 두 집단 간의 독립표본 t-검정(Independent t-test)을 수행하여, 평균 가격 차이가 통계적으로 유의미한지 확인합니다.

4.2. 클린 뷰티(Clean at Sephora) 라벨의 프리미엄 효과 분석

'Clean at Sephora' 라벨이 붙은 제품이 일반 제품에 비해 더 비싸거나(프리미엄 가격 부여), 더 좋은 평점을 받는지 분석합니다.

- 시각화 기법: Boxplot(상자 수염 그림)을 활용하여 Clean 뷰티 여부에 따른 가격/평점 분포를 비교 시각화합니다.

5. 결론 및 비즈니스 활용 방안

- 가격 정책 및 포지셔닝: EDA와 통계 분석을 통해 얻어진 카테고리별 평균 가격대를 참고하여, 신제품 출시 시 경쟁력 있는 가격 포지셔닝을 설정할 수 있습니다.
- 성분 마케팅: 소비자 평점에 긍정적인 영향을 미치거나, 프리미엄 가격대를 형성할 수 있는 특정 활성 성분(예: 레티놀, 비건 성분 등)을 파악하여 마케팅 소구점(USP)으로 활용합니다.
- 제품 개발 인사이트: 리뷰 수가 높으면서 평점이 낮은 제품군의 성분을 분석하여, 부작용을 유발하거나 만족도를 떨어뜨리는 성분

조합을 피하는 제품 기획이 가능합니다.